Defiende el servidor

Informe del taller · Versionado de código, datos, experimentos y modelos

Autora: Maria Isabell Guzman · Grupo A · Curso MLOps 2026-II · Clasificación binaria normal/ataque con UNSW-NB15 (normal = 0, ataque = 1, clase positiva = ataque)

1. Datos y preparación

El training-set tiene 175.341 filas y 45 columnas, sin valores faltantes: 56.000 conexiones normales y 119.341 ataques. Se usaron 42 variables predictoras; se excluyeron **label** (la respuesta), **attack_cat** (revela la respuesta) e **id** (solo identifica filas).

Archivo	Filas	SHA-256
UNSW_NB15_training-set.csv	175.341	`bec7dd5ec88dc2a0ccc7a07879d338395ed7421750f675fd0339e07dfe0648fa`
UNSW_NB15_testing-set.csv	82.332	`734fe6642edf758f7c94d7d9149426b49d202fe8e7bf0bef47392489c3c0a559`

Duplicados y contradicciones. Hay 9.748 grupos de entradas idénticas (74.301 ocurrencias adicionales sobre la primera fila, grupo máximo de 415). En 229 grupos la misma entrada aparece con etiquetas distintas. **Política:** conservar todas las filas y etiquetas, mantener cada grupo en una sola partición y dejar visibles las contradicciones, sin eliminarlas ni reetiquetarlas.

Particiones. Con StratifiedGroupKFold (semilla 42) se tomó el primer fold: entrenamiento de 140.274 filas (44.800 normales, 95.474 ataques) y validación de 35.067 (11.200 normales, 23.867 ataques), sin grupos compartidos. Las mismas particiones se usaron en los cuatro experimentos. El test no intervino en la elección del modelo ni del umbral.

Preprocesamiento. Un único Pipeline de scikit-learn: imputación por mediana y escalado estándar para variables numéricas; imputación por moda y OneHotEncoder para categóricas; y el estimador. Todo se ajustó solo con entrenamiento. Los datos originales y los preparados están versionados con DVC en un remote en DagsHub (huellas de directorio: raw `fe93051ae209ffb0128a31e7a478c009.dir`; procesados `a065edaae55501c53239ceade3a3a8e0.dir`).

2. Experimentos (validación)

Cuatro configuraciones de dos familias (regresión logística y árbol de decisión), con el mismo split y la misma semilla. En cada una el umbral se eligió maximizando macro-F1 sobre los scores de validación. Precision, recall y F1 usan zero_division = 0; FPR = FP/(FP+TN), definida como 0 si no hay negativos reales. Matriz en orden TN / FP / FN / TP. Cifras redondeadas a 4 decimales; los valores completos están en *experimentos.csv*.

Configuración	Hipótesis / cambio	Umbral	Recall	Precision	FPR	Macro-F1	TN / FP / FN / TP
LR C=1 (lr_c1)	Referencia lineal balanceada	0,3904	0,9789	0,9309	0,1549	0,9243	9465 / 1735 / 503 / 23364
LR C=0,1 (lr_c0_1)	Más regularización que C=1	0,4017	0,9798	0,9286	0,1604	0,9227	9403 / 1797 / 482 / 23385
Árbol prof. 5 (dt_depth5)	Familia no lineal, profundidad limitada	0,5302	0,9401	0,9565	0,0911	0,9204	10180 / 1020 / 1429 / 22438
Árbol prof. 15 (dt_depth15)	Más capacidad que prof. 5	0,3538	0,9559	0,9655	0,0728	**0,9391**	10385 / 815 / 1053 / 22814

El árbol de profundidad 15 logró el mayor macro-F1 y la menor FPR; LR C=1 logró más recall. **Aviso sobre la selección:** *seleccion.json* eligió LR C=1 como base de v1/v2 y optimizó su umbral con validación; no escogió el mejor macro-F1 global de las cuatro filas. Esa decisión se conserva para respetar la congelación previa al test y se declara como limitación del proceso.

3. Versiones v1 y v2

v1 (tag Git v1): regresión logística C=1 con umbral 0,5. **v2** (tag Git v2): el mismo modelo y preprocesamiento con un único cambio, el umbral, que pasa a 0,3904 (elegido solo con validación para maximizar macro-F1). Son revisiones distintas en Hugging Face, cada una con su propio *config.json*, aunque el estimador entrenado es el mismo (mismo hash).

Versión (validación)	Umbral	Recall	Precision	FPR	Macro-F1	TN / FP / FN / TP
v1	0,5000	0,9540	0,9479	0,1117	0,9226	9949 / 1251 / 1099 / 22768
v2	0,3904	0,9789	0,9309	0,1549	0,9243	9465 / 1735 / 503 / 23364

Qué mejora y qué empeora. v2 sube el recall (+0,0250) y el macro-F1 (+0,0016), pero baja la precision (–0,0170) y sube la FPR (+0,0432). Se aceptan 484 falsos positivos adicionales a cambio de 596 falsos negativos menos: la política prioriza detectar ataques a costa de más alertas sobre tráfico normal.

Trazabilidad	Identificador
Código v1 / v2 (Git)	`c2891e168109f7ab89dec90ce8d188ac687c1539` / `f83efdcbb4eb75db01b4f27a79ed4a6393cc6e3c`
Hugging Face v1	`04f723fe871e9b2f3b10b2ccd88cb2b45f587b53`
Hugging Face v2	`03e583e00e2c3d5dda0d0eb1fb9364ab1b86c2d6`
Run MLflow (pipeline)	`ffdf524d57f749d28b5ed7fceb0fa0bf`
SHA-256 del modelo	`e0f3019485ecfaa7418c7d4c31b7d130b1c5f003162de5f925d83561b7683dc3`

4. Prueba de recuperación

En un checkout nuevo del commit `ec8b14923f3a5539250030045b47793c8637d4f8` se instalaron las dependencias fijadas, se hizo *dvc pull* y se verificaron los hashes de los datos. Se descargaron v1 y v2 por su SHA completo desde Hugging Face y se cargaron los pipelines. Sobre una muestra fija de 25 filas de validación coincidieron row_id, etiquetas y clases predichas con las salidas previas; la diferencia absoluta máxima de probabilidades fue $2{,}2\times10^{-16}$ para cada versión, dentro de la tolerancia de 1×10^{-12}. Bitácora, hashes y comparaciones: *evidencias/recuperacion/run-20261025T195751Z/*.

5. Evaluación única en test

Con v2 congelada se evaluó una sola vez el testing-set completo: 82.332 filas, sin descartar ninguna (37.000 normales y 45.332 ataques). Regla: ataque si score >= 0,3904. Matriz: TN = 23.531, FP = 13.469, FN = 1.784, TP = 43.548. Accuracy: 0,8147.

Métrica (umbral 0,3904)	Validación	Test	Cambio
Recall de ataque	0,9789	0,9606	–0,0183
Precision de ataque	0,9309	0,7638	–0,1671
FPR	0,1549	0,3640	+0,2091
Macro-F1	0,9243	0,8031	–0,1212

No se reajustaron ni el modelo ni el umbral. Solapamiento por huella de predictores: 6.930 filas de test (1.047 grupos) coinciden con entrenamiento y 1.611 filas (255 grupos) con validación; ningún grupo comparte las tres particiones. Evidencias fila a fila en *predicciones-test.csv* y *metricas-test.json*.

6. Limitaciones y conclusión

El rendimiento de validación no se trasladó por completo al test: la precision, el macro-F1 y el recall bajaron y la FPR subió, de modo que más de un tercio del tráfico normal del test se marcó como ataque. El solapamiento de patrones idénticos entre test y desarrollo, y las etiquetas contradictorias dentro de algunos grupos, dificultan interpretar la generalización y el techo de rendimiento. Se usó un solo split agrupado con semilla fija: no se reporta variación entre semillas ni calibración independiente. La selección de v2 se centró en la curva de umbral de LR C=1 y no fue la mejor puntuación global entre las cuatro configuraciones. El umbral elegido eleva los falsos positivos, por lo que un uso operativo exigiría valorar el costo de las alertas y validar en el contexto real; además, UNSW-NB15 es un dataset histórico que no demuestra eficacia en una red actual. Estas limitaciones no justifican alterar retrospectivamente el resultado final.

Uso de IA. Codex ayudó a escribir y depurar scripts, revisar la coherencia de las evidencias y redactar el borrador de este informe; Claude ayudó a orientar el trabajo y a dar formato a este PDF. Las cifras, hashes, commits y run IDs provienen de los artefactos y salidas reales del repositorio, no se fabricaron resultados. La autora es responsable de la revisión y la entrega.